

# Analiza porównawcza zastosowań tradycyjnych oraz wariacyjnych autoenkoderów

Filip Ręka

Uniwersytet Marii Curie Skłodowskiej

16 stycznia 2022

## 1 Cel

## 2 Autoenkoder

- Zastosowania autoenkodera
- Problem generacji danych


## 3 Wariacyjny autoenkoder

- Generacja nowych danych

- Opisanie budowy modelu autoenkodera oraz jego zastosowań
- Przetworzenie problemów tradycyjnej architektury w celu generacji nowych danych
- Opisanie budowy wariacyjnego autoenkodera
- Generacja danych, podobnych do tych, na których model został wytrenowany

Autoenkoder składa się z dwóch części: enkodera oraz dekodera. Obie z nich są w pełni połączonymi sieciami neuronowymi, które również są połączone pomiędzy sobą. Zadaniem enkodera jest zakodowanie jego wejścia do kodu o stałej długości, co jest osiągnięte przez architekturę warstw, w której każda następna ma mniej neuronów niż poprzednia. Dekoder jest częścią, która z kodu, próbuje odwzorować zakodowane dane. Cały autoenkoder dostaje na warstwę wejściową oraz wyjściową te same dane, przez co jego sposób uczenia jest nazywany częściowo nadzorowanym.


# Architektura autoenkodera



Rysunek: Przykładowa architektura modelu

# Zastosowania autoenkodera

Głównym zadaniem autoenkodera jest kompresja. Funkcję tą, można zastosować do redukcji wymiarów czy odszumiania danych, co zawdzięczamy temu, że kompresja dokonywana przez model jest stratna. W ten sposób autoenkoder, musi zachować w kodzie jak najwięcej istotnych elementów.



**Rysunek:** Rekonstrukcja obrazu przy pomocy autoenkodera

Zaletą używania autoenkoderów w celu redukcji wymiarów w przeciwieństwie do metody analizy składowych głównych (PCA) jest ich możliwość nauki nieliniowych zależności pomiędzy wymiarami.


Aby wygenerować nowe dane, podobne do tych na których model został wytrenowany, potrzebujemy ściśle określonej dystrybucji według której punkty, reprezentujące skompresowane wejście, są rozłożone. Tradycyjna architektura nie zapewnia nam tego faktu, ani takich wymagać jak kompletności oraz ciągłości przestrzeni kodu. Przed treningiem nie wiadomo czy losowo wybrany punkt z przestrzeni, będzie generował sensowne dane.

# Wariacyjny autoenkoder

Wariacyjny autoenkoder rozwiązuje problemy z generacją nowych danych tradycyjnego modelu. Aby model był generacyjny, potrzebujemy ściśle ustalonej dystrybucji, z której losujemy punkty, na podstawie których generujemy dane. W przypadku modelu VAE, jest to wielowymiarowy rozkład normalny, opisywany za pomocą wektorów odchylenia standardowego  $\sigma$  oraz średniej  $\mu$ . Następnie z tych dystrybucji losujemy punkty  $z$ , które traktujemy jako kod, na podstawie, których rekonstruujemy wejście modelu. Aby wynikiem enkodera były punkty należące do wybranej dystrybucji, trzeba zmodyfikować funkcję straty. Poza błędem rekonstrukcji, obliczamy również dywergencję Kullbacka-Leiblera, która określa rozbieżność pomiędzy dwoma rozkładami prawdopodobieństwa.




# Budowa wariacyjnego autoenkodera



Rysunek: Przykład architektury modelu

# Generacja nowych danych

Posiadając enkoder, który generuje kod należący co ściśle określonej dystrybucji, można wybierając z niej losowe punkty generować dane.



**Rysunek:** Po lewej stronie są dane ze zbioru, a po prawej wygenerowane

Powyższy przykład przedstawia generację na podstawie zbioru danych MNIST.

Dziękuję za uwagę!